# MÉTODO MULTIVARIADO DE ANÁLISE ESTATÍSTICA: ANÁLISE FATORIAL

Leonardo dos Santos Freitas[1]

RESUMO: Este trabalho tem como objetivo aplicar a análise fatorial exploratória (AFE) para identificar agrupamentos latentes de características associadas a cereais matinais, com base em um conjunto de palavras comumente utilizadas para descrever esse tipo de produto. A análise visa compreender como essas palavras como Natural, Doce, energético, divertido, entre outras, se correlacionam e podem ser agrupadas em fatores interpretáveis. Foram utilizados métodos estatísticos de verificação de adequação dos dados, como o índice KMO e o teste de esfericidade de Bartlett, seguidos da extração de fatores por máxima verossimilhança e rotação Varimax. A análise resultou na identificação de quatro fatores principais, representando agrupamentos conceituais distintos, como atributos saudáveis e atributos ligados ao prazer ou à conveniência do consumo. Este estudo destaca a utilidade da AFE na redução de dimensionalidade e na interpretação de dados qualitativos, sendo uma ferramenta importante para pesquisas em marketing, psicometria e ciências do consumidor.

PALAVRAS-CHAVE: Análise Fatorial Exploratória, Cereais Matinais, Atributos de Produtos, Estatística Multivariada, Comportamento do Consumidor.

## 1. INTRODUÇÃO

No cenário atual de mercado, compreender como os consumidores percebem os atributos de um produto é fundamental para o desenvolvimento de estratégias eficazes de marketing e posicionamento. Em especial, produtos alimentícios como os cereais matinais são frequentemente associados a diversas características, como saúde, sabor, praticidade e apelo infantil. Diante disso, torna-se relevante identificar como essas percepções se organizam e se relacionam entre si.

Em diversas áreas do conhecimento, a análise de dados multivariados tornou-se essencial para interpretar fenômenos complexos que envolvem múltiplas variáveis. Entre as técnicas disponíveis, a análise fatorial exploratória (AFE) destaca-se por sua capacidade de reduzir a dimensionalidade de conjuntos de dados, identificando estruturas subjacentes que explicam os padrões de correlação entre variáveis observadas.

A AFE tem ampla aplicação nas ciências sociais, psicologia, marketing, educação, entre outras, sendo frequentemente utilizada para construção e validação de

instrumentos de medida, identificação de perfis de consumidores, ou ainda para agrupar variáveis latentes com base em padrões comuns. Seu objetivo principal é resumir muitos variáveis em um número menor de fatores, facilitando a interpretação dos dados e a tomada de decisões.

Neste trabalho, a análise fatorial é aplicada em um contexto de comportamento do consumidor, mais especificamente na percepção de atributos relacionados a cereais matinais. Foram utilizadas palavras frequentemente associadas a esses produtos, como natural, doce, nutritivo, energético, divertido, entre outras, com o intuito de identificar agrupamentos conceituais que possam representar dimensões latentes como saúde, prazer ou conveniência.

A aplicação da AFE permite compreender como os consumidores organizam cognitivamente essas percepções, o que pode oferecer subsídios relevantes para empresas do setor alimentício no desenvolvimento de produtos, comunicação de marketing e posicionamento de marca. Além disso, o estudo contribui para a difusão do uso de técnicas estatísticas robustas em investigações mercadológicas e comportamentais.

## 1.1 Justificativa

Entender como os consumidores percebem os atributos de produtos alimentícios, como cereais matinais, é fundamental para orientar decisões de marketing e desenvolvimento. A AFE permite identificar padrões ocultos entre essas percepções, agrupando características semelhantes em fatores interpretáveis. Este trabalho se justifica pela aplicação da AFE como uma ferramenta útil para revelar dimensões latentes nas avaliações dos consumidores, contribuindo para estratégias mais eficazes e fundamentadas no setor alimentício.

## 1.2 Objetivo

Aplicar a análise fatorial exploratória para identificar agrupamentos de percepções associadas a atributos de cereais matinais, com base em palavras descritivas utilizadas pelos consumidores.

# 2. REVISÃO BIBLIOGRÁFICA

## 2.1 CONCEITO

Método estatístico usado para descrever variabilidade entre variáveis correlacionadas, a Análise Fatorial teve seus primeiros trabalhos realizados por Charles Spearman e Karl Pearson, em 1904. Segundo Johnson e Wichern (2008, p. 481), "o objetivo essencial da análise fatorial é descrever, se possível, as relações de covariância entre muitas variáveis observadas em termos de menos variáveis não observadas chamadas de fatores."

Já Hair et al. (2009) “A análise fatorial fornece as ferramentas para analisar a estrutura das inter-relações (correlações) em muitos variáveis, definindo conjuntos de variáveis que são fortemente inter-relacionadas, conhecidos como fatores. Esses grupos de variáveis (fatores), que são por definição altamente Inter correlacionadas, são considerados como representantes de dimensões dentro dos dados.”

## 2.2 ANÁLISE FATORIAL ORTOGONAL

O objetivo da análise fatorial é descrever a variabilidade original do vetor aleatório $Xp\times1$ em termos de um número menor $m$ de variáveis aleatórias, chamadas de fatores comuns, que estão relacionadas com $X$ por meio de um modelo linear. Essa abordagem busca agrupar as variáveis originais $Xi$, com $i=1,\ldots, p$, em fatores que sejam mutuamente não correlacionados e que possam ser interpretados de maneira significativa. Com isso, pretende-se reduzir a dimensionalidade do problema, facilitando a análise e a interpretação dos dados sem perder a essência da variabilidade contida nas variáveis observadas.

Queremos explicar as variáveis padronizadas $Zi, \ldots., Zp$ com $m$ fatores $F1, \ldots., Fm$ de tal forma que:

$$Z1 = L11F1 + \cdots + l1mFm + \epsilon 1$$
$$Z2 = L21F1 + \cdots + l1mFm + \epsilon 2$$
$$\vdots$$
$$Zp = Lp1F1 + \cdots + l1mFm + \epsilon \mathrm{p}$$

Esse sistema permite reduzir a complexidade dos dados ao resumir a informação contida em muitas variáveis observadas em poucos fatores comuns *F1,…, Fm* que capturam as estruturas subjacentes do conjunto de dados. Cada *Zi* é explicado parcialmente pelos fatores comuns e parcialmente por um ruído próprio $\epsilon p$.

No modelo ortogonal, fazemos as seguintes suposições sobre ***f*** e seus elementos: $E(Fj) = 0$ e $Var(Fj) = 1, j = 1, \ldots, m$. Além disso, admitimos:

a) $Cov(f) = \boldsymbol{I}m$, na qual $\boldsymbol{I}m$ é a matriz identidade de ordem $m$, ou seja, os fatores comuns não são correlacionados.

b) $E(\epsilon) = \mathbf{0}$.

c) $Cov(\epsilon) = \boldsymbol{\psi} = diag\{\psi 1, \ldots., \psi p\}$.

d) $Cov(f, \epsilon) = \mathbf{0}$.

## 2.3 MÉTODOS DE OBTENÇÃO DE FATORES

Decidir quantos fatores extrair é uma etapa crítica e, até hoje, não existe uma base quantitativa definitiva para essa escolha. Por isso, pesquisadores utilizam critérios práticos.

Segundo Hair, o mais comum é o critério da raiz latente (ou método dos componentes principais), que propõe manter apenas os fatores com autovalores maiores que 1, pois esses explicam mais variância do que uma única variável original.

$$P = \sum_{i=1}^{p} \lambda ieiei^T = ( \sqrt{\lambda}\, 1e1 \ \dots \ \sqrt{\lambda pep} \begin{pmatrix} \sqrt{\lambda} 1e1^T \\ \vdots \\ \sqrt{\lambda} pep^T \end{pmatrix} = LL^T$$

Outro critério é o método da máxima verossimilhança, que segundo Artes et al, supõe-se que as variáveis envolvidas seguem uma distribuição normal multivariada. Esse método em geral, não é indicado para casos em que a suposição de normalidade das variáveis não esteja satisfeita.

$$L(P) = \frac{1}{(2\pi)^{\frac{np}{2}} |P|^{\frac{np}{2}}} \exp\{-\frac{1}{2} \sum_{j=1}^{n} ZpT\, p - 1\, Zj\}$$

Ou seja,

$$L(L, \psi) = \frac{1}{(2\pi)^{\frac{np}{2}} |LL^T + \psi|^{\frac{np}{2}}} \exp\{-\frac{1}{2} \sum_{j=1}^{n} Zi^T (LL^T + \psi)^{-1} zj\}$$

## 2.4 ESCOLHA DO NÚMERO DE FATORES

A escolha do número de fatores é uma das tarefas mais importantes em uma AF. Essa etapa constitui uma decisão crucial que pode influenciar diretamente a qualidade e a utilidade dos resultados obtidos. A extração de um número insuficiente de fatores pode levar à negligência de padrões ou estruturas

relevantes presentes nos dados, comprometendo a capacidade explicativa da análise. Em contrapartida, a extração excessiva de fatores pode gerar soluções redundantes ou difíceis de interpretar, dificultando a compreensão dos resultados. Para apoiar essa decisão, a literatura especializada oferece diversos critérios estatísticos, entre os quais se destacam o critério do autovalor (ou raiz latente), o percentual acumulado da variância explicada, o gráfico de autovalores (*screeplot*), além de abordagens baseadas em conhecimento prévio ou fundamentos teóricos relacionados ao construto investigado. Contudo, esses critérios frequentemente não convergem, uma vez que cada método se fundamenta em princípios estatísticos distintos e, por vezes, envolve julgamentos subjetivos. Alguns métodos são:

a) **Critério da porcentagem da variância explicada:** O número determinado de modo que o conjunto de fatores comuns explique uma porcentagem predefinida da variabilidade total, por exemplo, desejamos explicar pelo menos 70% da variabilidade dos dados.

b) **Critério da comunalidade explicada:** Esse critério determina que os fatores comuns expliquem uma porcentagem predefinida da variância de cada variável individualmente, ou seja, as comunalidades.

c) **Critério de Kaiser:** Também conhecido como critério da raiz latente, determina que, no caso de análise de dados padronizados, o número de fatores deve ser igual ao n° de $\lambda j$ maiores ou iguais a um.

d) **Critério do gráfico dos autovalores:** Nesse critério, o número ótimo de fatores é obtido quando a variação da explicação entre fatores consecutivos passa a ser pequena.

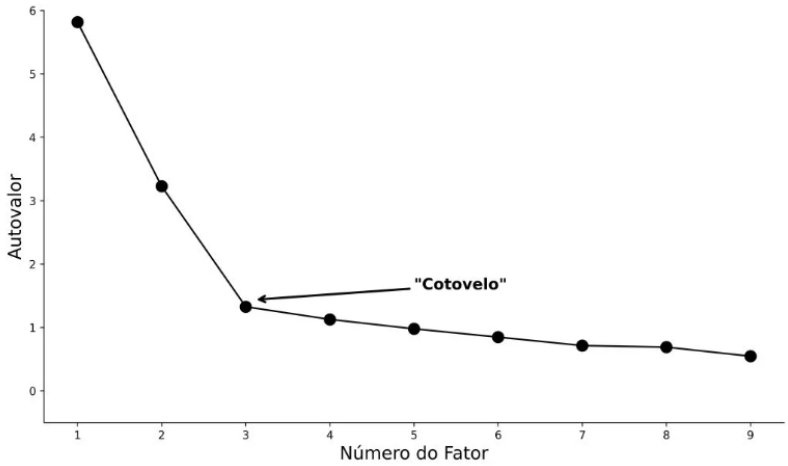


## 2.5 ROTAÇÕES ORTOGONAIS

Esses novos eixos equivalem a novos fatores (fatores rotacionados). Esse resultado é útil principalmente quando a solução inicial de uma análise fatorial não for facilmente interpretável. Assim, podemos usar as rotações para ter melhores soluções. Então temos:

**CRITÉRIO VARIMAX: (Kaiser 1958)**

**Objetivo:** Encontrar fatores com variabilidade máxima nas cargas fatoriais. Seja $li^*j$ o coeficiente da e - ésima variável no j – ésimo fator após a rotação. Seja:

$$\mathrm{V} = \frac{1}{p}[\sum_{i=1}^{p} lij^4 - \frac{1}{p}(\sum_{i=1}^{p} lij^2] \text{ em que } lij = \frac{lij^*}{hi}$$

O critério da varimax busca $lij$ que levam a V máximo para $i = 1, \ldots., p$.

**CRITÉRIO QUARTIMAX: (Jobson 1996)**

**Objetivo:** Encontrar fatores que levam ao máximo da variabilidade dos quadrados das cargas fatoriais sobre todos os fatores. Seja $lij^*$ o coeficiente da i – ésima variável no j- ésimo fator após a rotação. Seja:

$$\mathrm{VQ} = \frac{1}{pm}\sum_{j=1}^{m}\sum_{i=1}^{p} lij^4 - \frac{1}{pm}\sum_{i=1}^{m}\sum_{i=1}^{p}(lij^*)^2$$

O critério da quartimax busca $lij$ que levam a VQ máximo.

**CRITÉRIO ORTHOMAX: (Jobson 1996)**

**Objetivo:** Seja $lij^*$ o coeficiente da i – ésima variável no j- ésimo fator após a rotação. Seja,

$$\mathrm{Vm} = \frac{1}{pm}\sum_{j=1}^{m}[\sum_{i=1}^{p} lij^4 - \frac{\gamma}{p}\sum_{i=1}^{m}\sum_{i=1}^{p}(lij^*)^2]$$

O critério da orthomax busca $lij$ que levam a Vm máximo:

- Se $\gamma = o$, temos o critério quartimax;
- Se $\gamma = 1$, o critério se assemelha ao varimax;
- Se $\gamma = o,5$, o critério se chama biquartimax;

## 2.6 ESTIMAÇÃO DOS ESCORES F PARA CADA ELEMENTO AMOSTRAL

É suposto que cada indivíduo na amostra tenha um valor para cada um dos fatores comuns. Esses valores são chamados de escores fatoriais, desenvolvidos por Spearman (1904), calculando o índice geral de inteligência para os indivíduos submetidos a análise.

- **Método dos mínimos quadrados ponderados**

O modelo acima se assemelha a um modelo de regressão linear, comparando as partes percebemos que *Xi* - *μ* desempenha o papel da variável dependente, o Φ da matriz de variáveis independentes, *Fi* o do vetor de parâmetros e ξi o vetor de erros. Quando determinamos que P si é conhecido, recomenda-se a utilização do método dos mínimos quadrados ponderados ao invés do método de mínimos quadrados ordinários. Nesse método, o previsor de *Fi* será aquele que minimizar a equação a seguir:

$$Q(\mathbf{F}_i) = (\boldsymbol{X}_i - \boldsymbol{\mu} - \boldsymbol{\Phi}\mathbf{F}_i)^\intercal \boldsymbol{\Psi}^{-1}(\boldsymbol{X}_i - \boldsymbol{\mu} - \boldsymbol{\Phi}\mathbf{F}_i)$$

O previsor será de:

$$\hat{\mathbf{F}}_i = (\boldsymbol{\Phi}^\intercal \boldsymbol{\Psi}^{-1}\boldsymbol{\Phi})^{-1}\boldsymbol{\Phi}_\intercal \boldsymbol{\Psi}^{-1}(\boldsymbol{X}_i - \boldsymbol{\mu})$$

- **Método da regressão:**

Para estimar o *Fi* é necessário fazer a previsão através da esperança condicional de *F* dado Xi. Para isso é necessário que *μ,Φ* e *Ψ* sejam conhecidos, além da suposição que os fatores F e o vetor de erros *(ξ)* sejam normalmente distribuídos. Os detalhes dos resultados desse método não serão apresentados nesse estudo. Por fim temos que o previsor de *Fi* será dado por:

$$\hat{\mathbf{F}}_i = \boldsymbol{\Phi}^\intercal \boldsymbol{\Sigma}^{-1}(\boldsymbol{X}_i - \boldsymbol{\mu}) = \boldsymbol{\Phi}^\intercal(\boldsymbol{\Phi}\boldsymbol{\Phi}^\intercal + \boldsymbol{\Psi})^{-1}(\boldsymbol{X}_i - \boldsymbol{\mu})$$

## 2.7 ADEQUABILIDADE DA ANÁLISE FATORIAL

É necessário apresentar medidas adicionais que ajudam a entender a viabilidade da aplicação de uma Análise Fatorial a um conjunto de dados. Serão apresentadas três medidas para auxiliar nessa viabilidade:

**a) Matriz anti-imagem:**

A análise fatorial parte da premissa de que deve haver uma estrutura clara de dependência entre as variáveis analisadas. Essa estrutura é representada pela matriz de covariância ou pela matriz de correlação. Quando tal estrutura está presente, é possível supor que uma variável pode ser, em certa medida, prevista a partir das demais. Para verificar essa possibilidade, calculam-se os coeficientes de correlação parcial entre os pares de variáveis, controlando o efeito das demais. O ideal é que esses coeficientes sejam baixos, indicando que as variáveis compartilham variação comum. A matriz formada por esses coeficientes, com os sinais invertido.

**b) MSA: Mensure of sampling adequacy:**

MSA deve ser calculada separadamente para cada variável, pois o objetivo é verificar se uma dada variável pode ser explicada pelas demais. Valores baixos indicam que a variável analisada por ser retirada da análise sem maiores prejuízos. Essa medida é dada pela seguinte formula:

$$MSA = \frac{\sum_{j=1}^{p} r_{ij}^2}{\sum_{j=1}^{p} r_{ij}^2 + \sum_{j=1}^{p} a_{ij}^2}$$

**c) KMO: Kaiser – Meyer – Olkin:**

O coeficiente de KMO parte do princípio da matriz anti-imagem, ou seja, as correlações parciais entre as variáveis. O coeficiente é dado por:

$$KMO = \frac{\sum_{i=1}^{p}\sum_{j=1}^{p} r_{ij}^2}{\sum_{i=1}^{p}\sum_{j=1}^{p} r_{ij}^2 + \sum_{i=1}^{p}\sum_{j=1}^{p} a_{ij}^2}$$

em que, $a^2 ij$ é a correlação parcial entre duas variáveis X, eliminando o efeito das demais variáveis. O coeficiente de KMO é interpretado na literatura baseado na proposta feita por Kaiser e Rice (1974), apresentada na tabela a seguir:

| KMO | Intepretação |
|---|---|
| 0,90-1,00 | Excelente |
| 0,80-0,90 | Ótimo |
| 0,70-0,80 | Bom |
| 0,60-0,70 | Regular |
| 0,50-0,60 | Ruim |
| 0,50-0,60 | Inadequado |

## 3. Case

### Estudo de Roberts & Lattin (1991) – Pesquisa de Percepção de Marcas de Cereais

Este estudo, realizado pela Kellogg Australia, envolveu uma pesquisa com 500 consumidores australianos, que avaliaram suas três marcas favoritas de cereais prontos para consumo em 25 atributos diferentes. As avaliações foram feitas utilizando uma escala de Likert de 5 pontos. Os dados coletados são ideais para análises fatoriais, pois permitem identificar fatores latentes que influenciam a percepção dos consumidores sobre as marcas de cereais.

**Características:** Filling, Natural, Fibre, Sweet, Easy, Salt, Satisfying, Energy, Fun, Kids, Soggy, Economical, Health, Family, Calories, Plain, Crisp, Regular, Sugar, Fruit, Process, Quality, Treat, Boring, Nutritious

## Importações e Configuração:

Importando bibliotecas essenciais:

- *pandas, numpy*: manipulação de dados.
- *matplotlib*: geração de gráficos.
- *sklearn e factor_analyzer*: análise fatorial.

```
import pandas as pd
import numpy as np
import scipy

import matplotlib.pyplot as plt
%matplotlib inline

from sklearn.datasets import load_digits
from sklearn.decomposition import FactorAnalysis
```

```
!pip install factor_analyzer==0.3.2
!pip install scipy==1.11.4

from factor_analyzer import FactorAnalyzer
```

```
df = pd.read_csv("cereal.csv")
df.head()
```

| | Cereals | Filling | Natural | Fibre | Sweet | Easy | Salt | Satisfying | Energy | Fun | ... | Plain | Crisp | Regular | Sugar | Fruit | Process | Quality | Treat | Boring | Nutritious |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | Weetabix | 5 | 5 | 5 | 1 | 2 | 1 | 5 | 4 | 1 | ... | 3 | 1 | 4 | 1 | 1 | 3 | 5 | 1 | 1 | 5 |
| 1 | SpecialK | 1 | 2 | 2 | 1 | 5 | 2 | 5 | 1 | 1 | ... | 5 | 5 | 1 | 2 | 1 | 5 | 2 | 1 | 1 | 3 |
| 2 | SpecialK | 5 | 4 | 5 | 5 | 5 | 3 | 5 | 5 | 5 | ... | 1 | 5 | 4 | 3 | 1 | 2 | 5 | 4 | 1 | 5 |
| 3 | CMuesli | 5 | 5 | 5 | 3 | 5 | 2 | 5 | 5 | 5 | ... | 1 | 1 | 4 | 2 | 5 | 2 | 5 | 5 | 1 | 5 |
| 4 | CornFlakes | 4 | 5 | 3 | 2 | 5 | 2 | 5 | 4 | 5 | ... | 1 | 5 | 3 | 1 | 1 | 3 | 5 | 5 | 1 | 4 |

5 rows × 26 columns

## Análise Fatorial Inicial (25 fatores):

Executa análise com 25 fatores apenas para identificar quantos são significativos, observando os autovalores.

```python
X = df.iloc[:, 2:27]
X
```

| | Natural | Fibre | Sweet | Easy | Salt | Satisfying | Energy | Fun | Kids | Soggy | ... | Plain | Crisp | Regular | Sugar | Fruit | Process | Quality | Treat | Boring | Nutritious |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| **0** | 5 | 5 | 1 | 2 | 1 | 5 | 4 | 1 | 4 | 5 | ... | 3 | 1 | 4 | 1 | 1 | 3 | 5 | 1 | 1 | 5 |
| **1** | 2 | 2 | 1 | 5 | 2 | 5 | 1 | 1 | 5 | 3 | ... | 5 | 5 | 1 | 2 | 1 | 5 | 2 | 1 | 1 | 3 |
| **2** | 4 | 5 | 5 | 5 | 3 | 5 | 5 | 5 | 5 | 3 | ... | 1 | 5 | 4 | 3 | 1 | 2 | 5 | 4 | 1 | 5 |
| **3** | 5 | 5 | 3 | 5 | 2 | 5 | 5 | 5 | 5 | 3 | ... | 1 | 1 | 4 | 2 | 5 | 2 | 5 | 5 | 1 | 5 |
| **4** | 5 | 3 | 2 | 5 | 2 | 5 | 4 | 5 | 5 | 1 | ... | 1 | 5 | 3 | 1 | 1 | 3 | 5 | 5 | 1 | 4 |
| **...** | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| **230** | 4 | 4 | 1 | 4 | 2 | 3 | 3 | 2 | 4 | 3 | ... | 4 | 3 | 4 | 1 | 1 | 3 | 4 | 2 | 2 | 4 |
| **231** | 4 | 4 | 3 | 4 | 3 | 4 | 4 | 4 | 4 | 1 | ... | 1 | 4 | 4 | 3 | 4 | 2 | 4 | 4 | 1 | 4 |
| **232** | 4 | 4 | 1 | 4 | 1 | 4 | 4 | 3 | 4 | 2 | ... | 3 | 3 | 4 | 1 | 1 | 2 | 3 | 3 | 2 | 4 |
| **233** | 3 | 3 | 3 | 4 | 2 | 3 | 3 | 2 | 3 | 2 | ... | 3 | 2 | 3 | 2 | 1 | 3 | 3 | 2 | 2 | 3 |
| **234** | 4 | 4 | 1 | 4 | 1 | 4 | 3 | 2 | 4 | 3 | ... | 2 | 2 | 4 | 1 | 1 | 2 | 4 | 2 | 3 | 4 |

235 rows × 24 columns

```python
# Criar o objeto de análise fatorial e realizar a análise fatorial

fa=FactorAnalyzer(n_factors=25, rotation='varimax')
fa.fit(X)

# Check Eigenvalues
ev, v = fa.get_eigenvalues()
ev
```

```
array([5.99140968, 3.81199778, 2.49674494, 1.64453944, 1.07726628,
       0.9329784 , 0.835731  , 0.73191423, 0.70018125, 0.67070579,
       0.64106016, 0.54244882, 0.52499918, 0.48363248, 0.41454111,
       0.38669853, 0.36182149, 0.336638  , 0.29409425, 0.27415937,
       0.24466064, 0.23556771, 0.20194788, 0.16426158])
```

## Gráfico Scree Plot:

Gera um gráfico de dispersão com os autovalores dos fatores. A linha vermelha indica o ponto de corte (autovalor > 1).

```python
# Criar scree plot usando matplolib

plt.figure(figsize=(20,10))
plt.scatter(range(1, X.shape[1]+1), ev)
plt.plot(range(1, X.shape[1]+1), ev)
plt.title('Scree Plot - Eigenvalues dos Fatores')
plt.xlabel('Número do Fator')
plt.ylabel('Autovalor (soma dos quadrados das cargas)')
plt.axhline(y=1, color='red', linestyle='--')  # Linha de referência do critério de Kaiser

plt.grid()
plt.show()
```

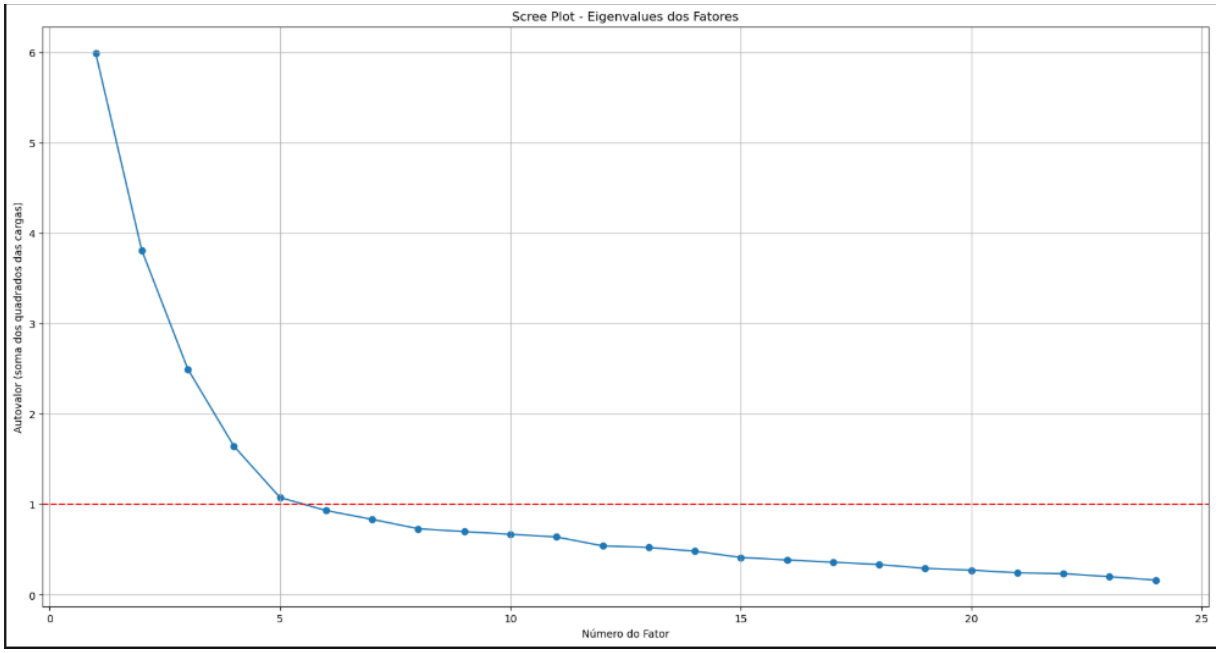


## Redução para 4 fatores:

Reduz o número de fatores para 4 com base no critério de Kaiser.

```
# Vamos considerar 4 fatores

#Análise Fatorial com fatores não rotacionais

fa = FactorAnalyzer(n_factors=4, rotation=None)
fa.fit(X)

FactorAnalyzer
FactorAnalyzer(n_factors=4, rotation=None, rotation_kwargs={})
```

## Extração das cargas fatoriais:

Mostra como cada variável contribui para cada fator.

```
# Matriz L de cargas fatoriais estimada

L = fa.loadings_
np.round(L, 2)

array([[ 0.73, -0.22, -0.11,  0.12],
       [ 0.72, -0.22, -0.31,  0.19],
       [ 0.05,  0.74, -0.21,  0.15],
       [ 0.31,  0.15,  0.19,  0.12],
       [-0.24,  0.5 , -0.14,  0.42],
       [ 0.69,  0.2 ,  0.15,  0.16],
       [ 0.67,  0.15, -0.07,  0.11],
       [ 0.38,  0.51,  0.2 , -0.14],
       [ 0.21,  0.29,  0.76,  0.12],
       [-0.1 , -0.23,  0.15,  0.39],
       [ 0.16, -0.22,  0.47,  0.11],
       [ 0.82, -0.28, -0.12,  0.11],
       [ 0.3 ,  0.23,  0.67,  0.02],
       [-0.2 ,  0.55, -0.17,  0.2 ],
       [-0.3 , -0.37,  0.23,  0.43],
       [ 0.29,  0.46,  0.2 , -0.15],
       [ 0.58, -0.11, -0.19,  0.1 ],
       [-0.28,  0.73, -0.25,  0.27],
       [ 0.36,  0.26, -0.48, -0.13],
       [-0.3 ,  0.26,  0.01,  0.24],
       [ 0.74, -0.11,  0.04,  0.01],
       [ 0.46,  0.59,  0.06, -0.18],
       [-0.39, -0.28, -0.08,  0.32],
       [ 0.81, -0.19, -0.16,  0.18]])
```

## Análise com rotação varimax:

Utiliza a rotação para facilitar a interpretação dos fatores.

```
fa.get_factor_variance()

(array([5.57508941, 3.35305457, 2.05064101, 1.08228784]),
 array([0.23229539, 0.13971061, 0.08544338, 0.04509533]),
 array([0.23229539, 0.372006  , 0.45744937, 0.5025447 ]))

# Análise fatorial com fatores rotacionados (varimax, testar outras)

fa = FactorAnalyzer(n_factors=4, rotation = 'varimax')
fa.fit(X)

FactorAnalyzer

FactorAnalyzer(n_factors=4, rotation='varimax', rotation_kwargs={})
```

## Interpretação dos Fatores

Identifica os fatores com base nas maiores cargas:

- **Fa1:** Saudável
- **Fa2:** Artificial / Não saudável
- **Fa3:** Familiar
- **Fa4:** Indulgência e Satisfação

```
# Matrix L de cargas fatoriais estimadas

L = pd.DataFrame(fa.loadings_)
np.round(L, 2)
L.index = X.columns
L.columns = ['Fa1', 'Fa2', 'Fa3', 'Fa4']
L
```

| | Fa1 | Fa2 | Fa3 | Fa4 |
|---|---|---|---|---|
| Natural | 0.750259 | -0.198162 | 0.071829 | 0.043789 |
| Fibre | 0.825044 | -0.099390 | -0.100966 | 0.028752 |
| Sweet | 0.047413 | 0.696390 | 0.086267 | 0.351098 |
| Easy | 0.231742 | 0.067923 | 0.333129 | 0.057562 |
| Salt | -0.098610 | 0.691030 | 0.016840 | -0.086973 |
| Satisfying | 0.589719 | 0.068877 | 0.433074 | 0.177883 |
| Energy | 0.627451 | 0.071637 | 0.207324 | 0.221854 |
| Fun | 0.150688 | 0.178230 | 0.434029 | 0.468913 |
| Kids | -0.045872 | 0.028134 | 0.850042 | -0.007909 |
| Soggy | 0.037480 | 0.016633 | 0.084649 | -0.480027 |
| Economical | 0.071270 | -0.276318 | 0.411229 | -0.242618 |
| Health | 0.841020 | -0.267016 | 0.072026 | 0.044439 |
| Family | 0.039973 | -0.061842 | 0.761821 | 0.075594 |
| Calories | -0.137780 | 0.613171 | -0.006691 | 0.128319 |

Maiores cargas nos primeiros fatores:

```
# Maiores cargas nos primeiros dois fatores

L.sort_values(by='Fa1', ascending=False).head(10)
```

| | Fa1 | Fa2 | Fa3 | Fa4 |
|---|---|---|---|---|
| **Nutritious** | 0.851029 | -0.150801 | 0.073748 | 0.051111 |
| **Health** | 0.841020 | -0.267016 | 0.072026 | 0.044439 |
| **Fibre** | 0.825044 | -0.099390 | -0.100966 | 0.028752 |
| **Natural** | 0.750259 | -0.198162 | 0.071829 | 0.043789 |
| **Quality** | 0.658534 | -0.225246 | 0.225794 | 0.162788 |
| **Energy** | 0.627451 | 0.071637 | 0.207324 | 0.221854 |
| **Regular** | 0.619924 | -0.082990 | -0.010358 | 0.088339 |
| **Satisfying** | 0.589719 | 0.068877 | 0.433074 | 0.177883 |
| **Fruit** | 0.380133 | 0.195736 | -0.247194 | 0.453558 |
| **Treat** | 0.233018 | 0.238936 | 0.358304 | 0.591760 |

```
np.round(fa.get_communalities(),2)

array([0.61, 0.7 , 0.62, 0.17, 0.5 , 0.57, 0.49, 0.46, 0.73, 0.24, 0.31,
       0.79, 0.59, 0.41, 0.47, 0.36, 0.4 , 0.74, 0.45, 0.22, 0.56, 0.59,
       0.34, 0.76])
```

**Primeiro fator:** Saudável:

```
# Maiores cargas nos primeiros dois fatores

L.sort_values(by='Fa1', ascending=False).head(10)
```

| | Fa1 | Fa2 | Fa3 | Fa4 |
|---|---|---|---|---|
| **Nutritious** | 0.851029 | -0.150801 | 0.073748 | 0.051111 |
| **Health** | 0.841020 | -0.267016 | 0.072026 | 0.044439 |
| **Fibre** | 0.825044 | -0.099390 | -0.100966 | 0.028752 |
| **Natural** | 0.750259 | -0.198162 | 0.071829 | 0.043789 |
| **Quality** | 0.658534 | -0.225246 | 0.225794 | 0.162788 |
| **Energy** | 0.627451 | 0.071637 | 0.207324 | 0.221854 |
| **Regular** | 0.619924 | -0.082990 | -0.010358 | 0.088339 |
| **Satisfying** | 0.589719 | 0.068877 | 0.433074 | 0.177883 |
| **Fruit** | 0.380133 | 0.195736 | -0.247194 | 0.453558 |
| **Treat** | 0.233018 | 0.238936 | 0.358304 | 0.591760 |

**Segundo fator:** Artificial:

```
L.sort_values(by='Fa2', ascending=False).head(10)
```

| | Fa1 | Fa2 | Fa3 | Fa4 |
|---|---|---|---|---|
| **Sugar** | -0.190665 | 0.822775 | -0.047049 | 0.162168 |
| **Sweet** | 0.047413 | 0.696390 | 0.086267 | 0.351098 |
| **Salt** | -0.098610 | 0.691030 | 0.016840 | -0.086973 |
| **Calories** | -0.137780 | 0.613171 | -0.006691 | 0.128319 |
| **Process** | -0.226377 | 0.381696 | 0.023879 | -0.135078 |
| **Treat** | 0.233018 | 0.238936 | 0.358304 | 0.591760 |
| **Fruit** | 0.380133 | 0.195736 | -0.247194 | 0.453558 |
| **Fun** | 0.150688 | 0.178230 | 0.434029 | 0.468913 |
| **Crisp** | 0.075151 | 0.155638 | 0.389520 | 0.419793 |
| **Energy** | 0.627451 | 0.071637 | 0.207324 | 0.221854 |

**Terceiro fator:** Familiar:

```
L.sort_values(by='Fa3', ascending=False).head(10)
```

| | Fa1 | Fa2 | Fa3 | Fa4 |
|---|---|---|---|---|
| **Kids** | -0.045872 | 0.028134 | 0.850042 | -0.007909 |
| **Family** | 0.039973 | -0.061842 | 0.761821 | 0.075594 |
| **Fun** | 0.150688 | 0.178230 | 0.434029 | 0.468913 |
| **Satisfying** | 0.589719 | 0.068877 | 0.433074 | 0.177883 |
| **Economical** | 0.071270 | -0.276318 | 0.411229 | -0.242618 |
| **Crisp** | 0.075151 | 0.155638 | 0.389520 | 0.419793 |
| **Treat** | 0.233018 | 0.238936 | 0.358304 | 0.591760 |
| **Easy** | 0.231742 | 0.067923 | 0.333129 | 0.057562 |
| **Quality** | 0.658534 | -0.225246 | 0.225794 | 0.162788 |
| **Energy** | 0.627451 | 0.071637 | 0.207324 | 0.221854 |

**Quarto fator:** Satisfação:

```
L.sort_values(by='Fa4', ascending=False).head(10)
```

| | Fa1 | Fa2 | Fa3 | Fa4 |
|---|---|---|---|---|
| **Treat** | 0.233018 | 0.238936 | 0.358304 | 0.591760 |
| **Fun** | 0.150688 | 0.178230 | 0.434029 | 0.468913 |
| **Fruit** | 0.380133 | 0.195736 | -0.247194 | 0.453558 |
| **Crisp** | 0.075151 | 0.155638 | 0.389520 | 0.419793 |
| **Sweet** | 0.047413 | 0.696390 | 0.086267 | 0.351098 |
| **Energy** | 0.627451 | 0.071637 | 0.207324 | 0.221854 |
| **Satisfying** | 0.589719 | 0.068877 | 0.433074 | 0.177883 |
| **Quality** | 0.658534 | -0.225246 | 0.225794 | 0.162788 |
| **Sugar** | -0.190665 | 0.822775 | -0.047049 | 0.162168 |
| **Calories** | -0.137780 | 0.613171 | -0.006691 | 0.128319 |

**Variância explicada:**

Mostra quanto da variância total é explicada por cada fator. Também calcula a proporção total.

```
# Variância explicada por cada fator:

fa.get_factor_variance()
```

```
(array([4.68877112, 2.61566349, 2.49950723, 2.25713098]),
 array([0.19536546, 0.10898598, 0.10414613, 0.09404712]),
 array([0.19536546, 0.30435144, 0.40849758, 0.5025447 ]))
```

```
np.sum(fa.get_factor_variance())
```

```
13.97437670337637
```

```
fa.get_factor_variance()/np.sum(fa.get_factor_variance())
```

```
array([[0.33552632, 0.18717568, 0.17886359, 0.16151926],
       [0.01398026, 0.00779899, 0.00745265, 0.00672997],
       [0.01398026, 0.02177925, 0.0292319 , 0.03596187]])
```

```
# Variância percentual explicada por cada fator:

np.round(fa.get_factor_variance()/np.sum(fa.get_factor_variance()),2)
```

```
array([[0.34, 0.19, 0.18, 0.16],
       [0.01, 0.01, 0.01, 0.01],
       [0.01, 0.02, 0.03, 0.04]])
```

```
df[['Fa1', 'Fa2','Fa3','Fa4']] = np.array(fa.fit_transform(X))[:, 0:4]
```

**Exploração dos resultados:**

Exibe os cereais com maiores escores em cada fator e permite investigar casos específicos, como o cereal de ID 15.

```
df.sort_values(by='Fa1', ascending=False).head(10)
```

| | Cereals | Filling | Natural | Fibre | Sweet | Easy | Salt | Satisfying | Energy | Fun | ... | Boring | Nutritious | Fa1 | Fa2 | Fa3 | Fa4 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| **40** | Sustain | 5 | 5 | 5 | 5 | 5 | 3 | 5 | 5 | 5 | ... | 1 | 5 | 1.827711 | 1.867018 | 0.691142 | 0.915932 |
| **73** | Komplete | 4 | 5 | 5 | 3 | 3 | 2 | 3 | 5 | 2 | ... | 3 | 5 | 1.778219 | 0.725700 | -2.041730 | -0.139463 |
| **158** | Vitabrit | 5 | 5 | 5 | 4 | 5 | 4 | 5 | 5 | 2 | ... | 1 | 5 | 1.747081 | 0.968091 | -0.016436 | -1.675357 |
| **31** | AllBran | 5 | 4 | 5 | 1 | 5 | 2 | 5 | 5 | 2 | ... | 4 | 5 | 1.673741 | -0.134329 | -1.157931 | -0.745910 |
| **206** | JustRight | 3 | 5 | 5 | 4 | 5 | 3 | 4 | 5 | 5 | ... | 2 | 5 | 1.655577 | 1.342514 | 0.705336 | 0.274670 |
| **3** | CMuesli | 5 | 5 | 5 | 3 | 5 | 2 | 5 | 5 | 5 | ... | 1 | 5 | 1.640304 | -0.012712 | 0.571300 | 1.038095 |
| **78** | Vitabrit | 5 | 5 | 5 | 2 | 4 | 1 | 5 | 5 | 2 | ... | 3 | 5 | 1.631055 | -0.276671 | 0.954199 | -1.139320 |
| **153** | Weetabix | 5 | 5 | 5 | 2 | 5 | 2 | 5 | 5 | 2 | ... | 1 | 5 | 1.623304 | -0.123433 | 1.234925 | -1.281149 |
| **208** | PMuesli | 4 | 5 | 5 | 3 | 5 | 1 | 5 | 4 | 3 | ... | 1 | 5 | 1.618179 | -0.623278 | -0.935918 | 1.198523 |
| **205** | Weetabix | 4 | 5 | 5 | 2 | 5 | 2 | 5 | 4 | 3 | ... | 3 | 5 | 1.601388 | 0.020870 | 0.551942 | -1.324081 |

**CONCLUSÃO:**

A análise fatorial realizada neste estudo teve como propósito reduzir a dimensionalidade dos dados relacionados a diferentes tipos de cereais, permitindo a identificação de estruturas latentes que explicam os padrões de correlação entre as variáveis observadas. A técnica demonstrou ser eficaz para resumir e interpretar as principais características dos produtos analisados, facilitando uma compreensão mais clara dos fatores que influenciam a percepção dos consumidores sobre esses alimentos.

Com base no critério de Kaiser, que considera significativos os fatores com autovalores maiores que um, foram selecionados quatro fatores principais que explicam uma parcela relevante da variância total dos dados. A aplicação da rotação *Varimax*, que busca maximizar a variância das cargas fatoriais, tornou a interpretação desses fatores mais intuitiva e precisa. A análise das variáveis com maiores cargas em cada fator permitiu rotular os componentes da seguinte forma: o primeiro fator está associado a atributos saudáveis, como maior teor de fibras, proteínas e vitaminas; o segundo se relaciona a características artificiais ou não saudáveis, como presença de açúcares adicionados e aditivos; o terceiro fator está ligado a produtos tradicionais e reconhecidos, possivelmente associados à familiaridade ou conveniência; e o quarto fator remete a aspectos sensoriais, como sabor, textura e prazer ao consumir.

Esses resultados têm aplicação prática relevante. Empresas do setor alimentício podem utilizar as informações obtidas para segmentar seus produtos com mais precisão, identificar lacunas no portfólio, alinhar estratégias de desenvolvimento de novos produtos com as preferências dos consumidores e criar campanhas de marketing mais eficazes, baseadas em atributos valorizados por cada segmento identificado. Além disso, os escores fatoriais atribuídos a cada cereal permitem ranquear os produtos conforme sua aderência a determinados perfis, como saudabilidade ou indulgência.

Do ponto de vista científico, este estudo evidencia o poder da análise fatorial como ferramenta para revelar padrões ocultos em dados complexos. Ao ir além da estatística descritiva convencional, a técnica oferece uma forma robusta de entender as inter-relações entre variáveis, proporcionando insights que podem fundamentar decisões estratégicas em diferentes áreas. A correta interpretação dos fatores

depende tanto do suporte estatístico quanto do conhecimento prático do domínio analisado, reforçando a importância de uma abordagem multidisciplinar.

Em síntese, a análise fatorial aplicada aos dados de cereais proporcionou uma visão aprofundada sobre os atributos que distinguem os produtos no mercado, contribuindo com subsídios valiosos para decisões orientadas por dados, seja no âmbito acadêmico, mercadológico ou estratégico.

## REFERÊNCIAS


AFONSO, Anabela; NUNES, Carla. **Probabilidades e Estatística**: aplicações e soluções em SPSS. Versão revista e aumentada. Évora: Universidade de Évora, 2019.

AZEVEDO, Paulo Roberto Medeiros de. **Introdução à Estatística**. 3. ed. [S. l.]: Edufrn, [s.d.].

COSTA, Giovani Glaucio de Oliveira. **Um procedimento inferencial para análise fatorial utilizando as técnicas Bootstrap e Jackknife: construção de intervalos de confiança e testes de hipóteses**. 2006. Tese (Doutorado em Engenharia Industrial) – Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, 2006.

CUNHA, Fabrício William da. **Guia de como elaborar um modelo preditivo para prevenir a evasão de alunos na EPT**. [S. l.]: Instituto Federal de Alagoas; ProfEPT.

DAMÁSIO, Bruno Figueiredo. Uso da análise fatorial exploratória em psicologia. **Avaliação Psicológica**, Porto Alegre, v. 11, n. 2, p. 213-228, 2012.

FACHEL, Jandyra Maria Guimarães. **Análise fatorial**. 1976. Dissertação (Mestrado em Estatística) – Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 1976.

HAIR JÚNIOR, Joseph F. et al. **Análise multivariada de dados**. Tradução Adonai Schlup Sant'Anna. 6. ed. Porto Alegre: Bookman, 2009.

JOHNSON, Richard A.; WICHERN, Dean W. ***Applied multivariate statistical analysis*.** 6. ed. Upper Saddle River: Pearson Prentice Hall, 2008.

MATOS, Daniel Abud Seabra; RODRIGUES, Erica Castilho. **Análise fatorial**. Brasília, DF: Enap, 2019.

PELLEGRINI, Jerônimo C. **Álgebra linear**. Versão 130. [S. l.]: [s.n.], 2015.

ROCHA, Henrique Martins. **Introdução às técnicas de análise fatorial e conjunta de dados**. [S. l.]: FGV EESP, [s.d.].